

数据学院大作业任务书及要求

课程名称：《python 程序设计》

课程学分：3.0

授课班级：计算机专业 24 级学生

学年学期：2025-2026-2

完成形式：个人 是否答辩：是

大作业任务书及要求：

任意选择机器学习任务或者数据分析任务，独立完成课程大作业。

大作业提交资料：

- ☐ Python 代码文件（jupyter 格式）
- ☐ 课程大作业报告（word 格式）
- ☐ 其它资料（数据集、模型等文件）
- ☐ 所有资料压缩后提交，命名格式：学号-班级-姓名-题目.rar

具体任务要求如下：

一、机器学习任务

1. 任务目标

本大作业旨在通过实践，加深同学们对 Python 编程语言及机器学习理论知识的理解，掌握数据处理、模型构建、训练、评估及优化的全过程。鼓励大家将所学知识应用于实际问题解决中，培养创新思维和独立解决问题的能力。

2. 任务描述

选择以下任一机器学习主题开展项目，完成从数据准备到模型评估的全过程，并提交一份详细报告及代码。

- ☐ **分类任务：**如手写数字识别（MNIST 数据集）、鸢尾花分类（Iris 数据集）、垃圾邮件识别等。
- ☐ **回归任务：**房价预测、股票价格预测、电影评分预测等。
- ☐ **聚类任务：**客户细分、新闻文章主题聚类、商品推荐系统中的用户群体划分等。

□ **自然语言处理任务：**情感分析（如微博情绪分析）、文本分类（新闻主题分类）、机器翻译等。

3. 任务要求

(1) 数据收集与预处理

□ 说明数据来源，进行必要的`数据清洗`（如处理缺失值、异常值、数据标准化等）。

□ 使用 Python 的数据分析库（如 Pandas、NumPy）进行数据探索和可视化（使用 Matplotlib 或 Seaborn）。

(2) 特征工程

□ 选择或构造有助于模型学习的特征。

□ 可以尝试特征选择方法（如递归特征消除、基于模型的特征选择）来优化特征集。

(3) 模型选择与实现

□ 至少选择并实现三种不同的机器学习模型（例如逻辑回归、支持向量机、决策树、随机森林、神经网络等）。

□ 使用 Scikit-learn 或其他相应库进行模型训练。

(4) 模型评估与对比

□ 使用交叉验证技术（如 K 折交叉验证）评估模型性能。

□ 比较不同模型的性能指标（如准确率、精确率、召回率、F1 分数、RMSE 等），并解释结果。

(5) 参数调优

□ 实现至少一种模型参数调优方法（如网格搜索、随机搜索）。

□ 分析调优前后的性能变化，讨论参数选择对模型性能的影响。

(6) 实验报告

□ 编写一份详细的实验报告，包括但不限于项目背景、数据描述、技术路线、关键代码片段、实验结果分析、遇到的问题及解决方案、未来工作展望等。

□ 报告应结构清晰、逻辑严密，附有必要的图表和代码注释。

二、数据分析任务

1. 任务目标

本次大作业旨在综合运用 Python 进行数据获取、处理、分析及可视化，让学生亲身体验数据科学项目的完整流程。通过实践，加深对 Python 编程、数据分析工具及统计学原理的理解，提升解决实际问题的能力。

2. 任务描述

选择以下任一数据分析主题开展项目，完成从数据准备到可视化分析的全过程并提交一份详细报告及代码。

- **社交媒体分析**：爬取特定话题的推特或微博数据，分析话题趋势、用户情感倾向、热门关键词等。
- **电商产品评论分析**：收集电商平台的商品评论，进行情感分析、关键词提取，探究影响产品评分的关键因素。
- **空气质量数据分析**：获取某城市或地区的空气质量指数历史数据，分析污染趋势、影响因素及健康影响。
- **电影票房预测**：爬取电影基本信息和票房数据，探索影响票房的因素，尝试构建票房预测模型。

3. 任务要求

(1) 数据爬取

- 使用 requests、BeautifulSoup 或 Scrapy 等库进行网页数据抓取。
- 至少抓取 2 个不同来源的网站数据。
- 遵守网站的 robots.txt 协议，尊重数据版权，合理合法地获取数据。

(2) 数据预处理

- 清洗数据，处理缺失值、异常值，进行数据类型转换。
- 使用 Pandas 进行数据整理，如合并、分组、筛选等操作。

(3) 探索性数据分析

- 运用统计方法（均值、中位数、标准差等）初步理解数据分布。

- 使用 Pandas、NumPy 进行基础分析，发现数据中的模式和异常。

(4) 统计分析

- 应用相关性分析、回归分析等统计方法深入探讨变量间关系。
- 可使用 SciPy、Statsmodels 等库进行高级统计分析。

(5) 数据可视化

- 利用 Matplotlib、Seaborn 或 Plotly 等库创建图表，直观展示分析结果。
- 包括但不限于条形图、饼图、散点图、线图、热力图等，确保图表清晰、信息传达准确。

(6) 实验报告

- 编写一份详细的实验报告，包括但不限于项目背景、数据描述、技术路线、关键代码片段、实验结果分析、未来工作展望等。
- 报告应结构清晰、逻辑严密，附有必要的图表和代码注释。

大作业评分标准

- 1) 实验方案设计与开发(40%):按照任务书要求, 为数据分析或人工智能应用问题设计/开发解决方案, 方案设计合理, 体现创新意识, 并能考虑社会、安全、文化及环节等制约因素。
- 2) 实验开展与结果分析(40%):能够根据实验方案配置实验环境、开展相关实验, 正确采集实验数据, 并对实验结果进行可视化分析和解释, 综合得到有效结论, 说明实验方案的合理性。文档规范, 结构合理, 图标制作精良;
- 3) 工具使用与自主学习(20%):能够合理运用相关工具、技术和资源; 具备自主学习能力, 能够运用或开发新工具取得创新结果;

教师签名: